

Zastosowanie metod sieci neuronowych do automatycznego wyznaczania właściwości próbki zawiesiny

Tomasz Jakubczyk

Promotor: dr hab. inż. **Andrzej Stachurski**

Agenda

Cel ogólny

Układ pomiarowy

Cele projektowe

Cele badawcze

Obecne rozwiązania


Zebrane dane

Prace planowane i zaczęte

- Zmiany ilości danych
- Wpływ przygotowania danych
- Niesiona informacja
- Badanie zmian struktury sieci
- Porównanie CNN z SVM
- Analiza tablicy pomyłek

Cel ogólny

System stwierdzający wybrane cechy próbki
pozwalające potencjalnie zidentyfikować substancję




Obraz rozproseniowy zawiesiny tlenku tytanu w wodzie

Układ pomiarowy


Laser

Próbka

Kamera



Układ pomiarowy




Cele projektowe

Wymagania funkcjonalne:

1. System rozpoznający zawiesinę na podstawie obrazu rozproszeniowego.
 - Wystarczy rozpoznawanie znanych zawiesin.
 - Wariant analizy obrazów statycznych
 - Wariant analizy obrazów dynamicznych (DSL)
2. System będzie przyjmował na wejście film (sekwencję obrazów) i zwracał dla niego etykietę.

Opcjonalne:


3. Pod-system rozpoznający istotne ustawienia kamery: czas ekspozycji, liczba klatek na sekundę.
4. System niewrażliwy (w pewnym zakresie) na czas ekspozycji.
5. Pod-system rozpoznający koncentrację zawiesiny.
6. Rozszerzenie rozpoznawania na mieszaniny zawiesin.



Cele projektowe

Wymagania niefunkcjonalne:

1. Sieć neuronowa
2. Szybka odpowiedź
3. PC z GPGPU
4. Rozsądny czas uczenia
5. Prosta obsługa




Przykładowa sieć neuronowa: AlexNet

<https://missinglink.ai/wp-content/uploads/2019/08/AlexNet-2012.png>

Cele badawcze

Sprawdzić:

1. Czy rozróżniane pomiary
2. Czy rozróżniane zawiesiny
3. Czy rozróżniane substancje niezależnie od koncentracji
4. Czy system jest w stanie ekstrapolować nieznane
5. Właściwości bijekcji: Próbką - Obraz
6. Możliwości charakteryzowania swobodnych kropeł zawiesiny na podstawie obrazów rozproszeniowych
7. Dokładności klasyfikacji przy zmniejszaniu ilości danych uczących
8. Dokładności klasyfikacji przy różnych głębokościach sieci



Symulacja kropli zawiesiny nano-cząstek

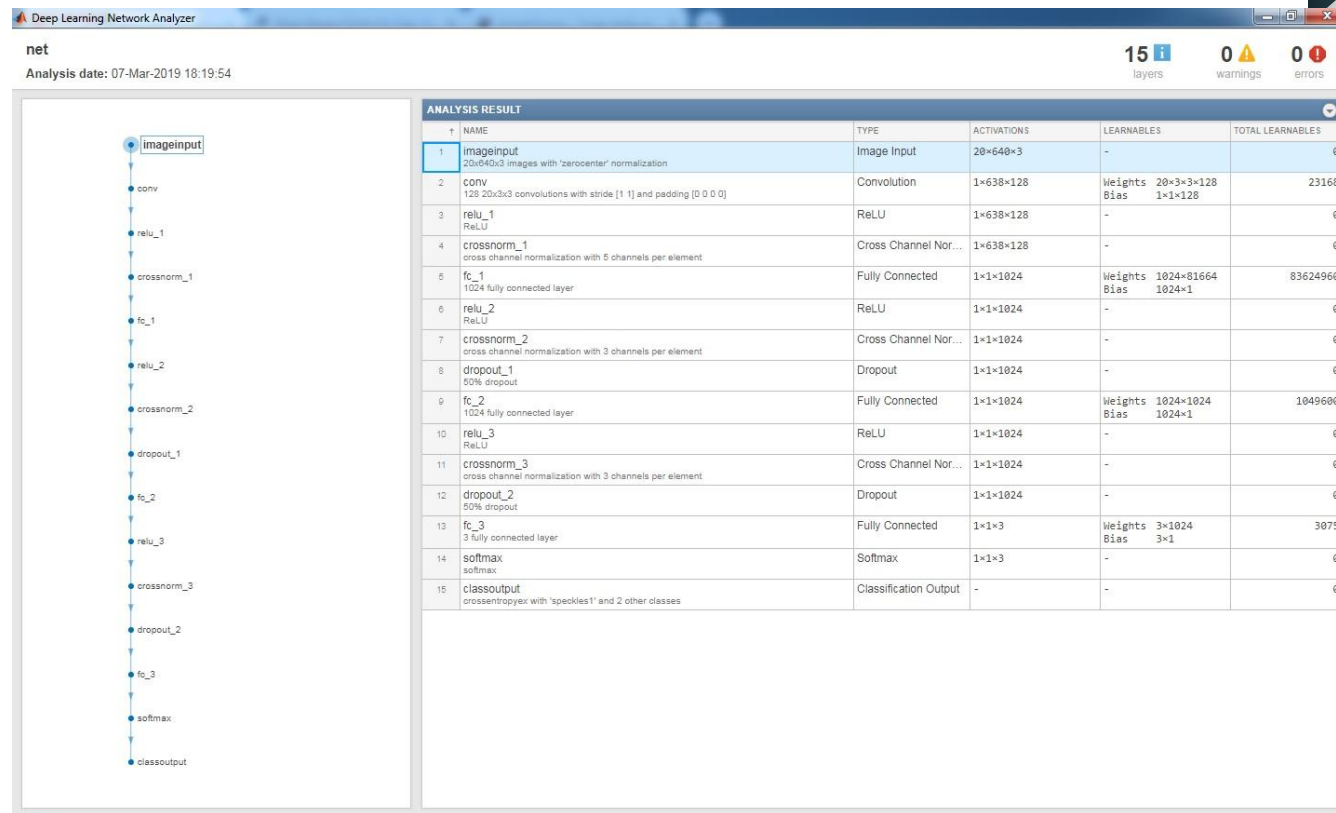
Pierwsze obiecujące rozwiązanie

Matlab

Rozmieszczenie istotnych informacji


RAW6 640x480

Płytka konwolucyjna sieć neuronowa




Warstwa konwolucyjna

Aktywacje warstwy conv1 638x128



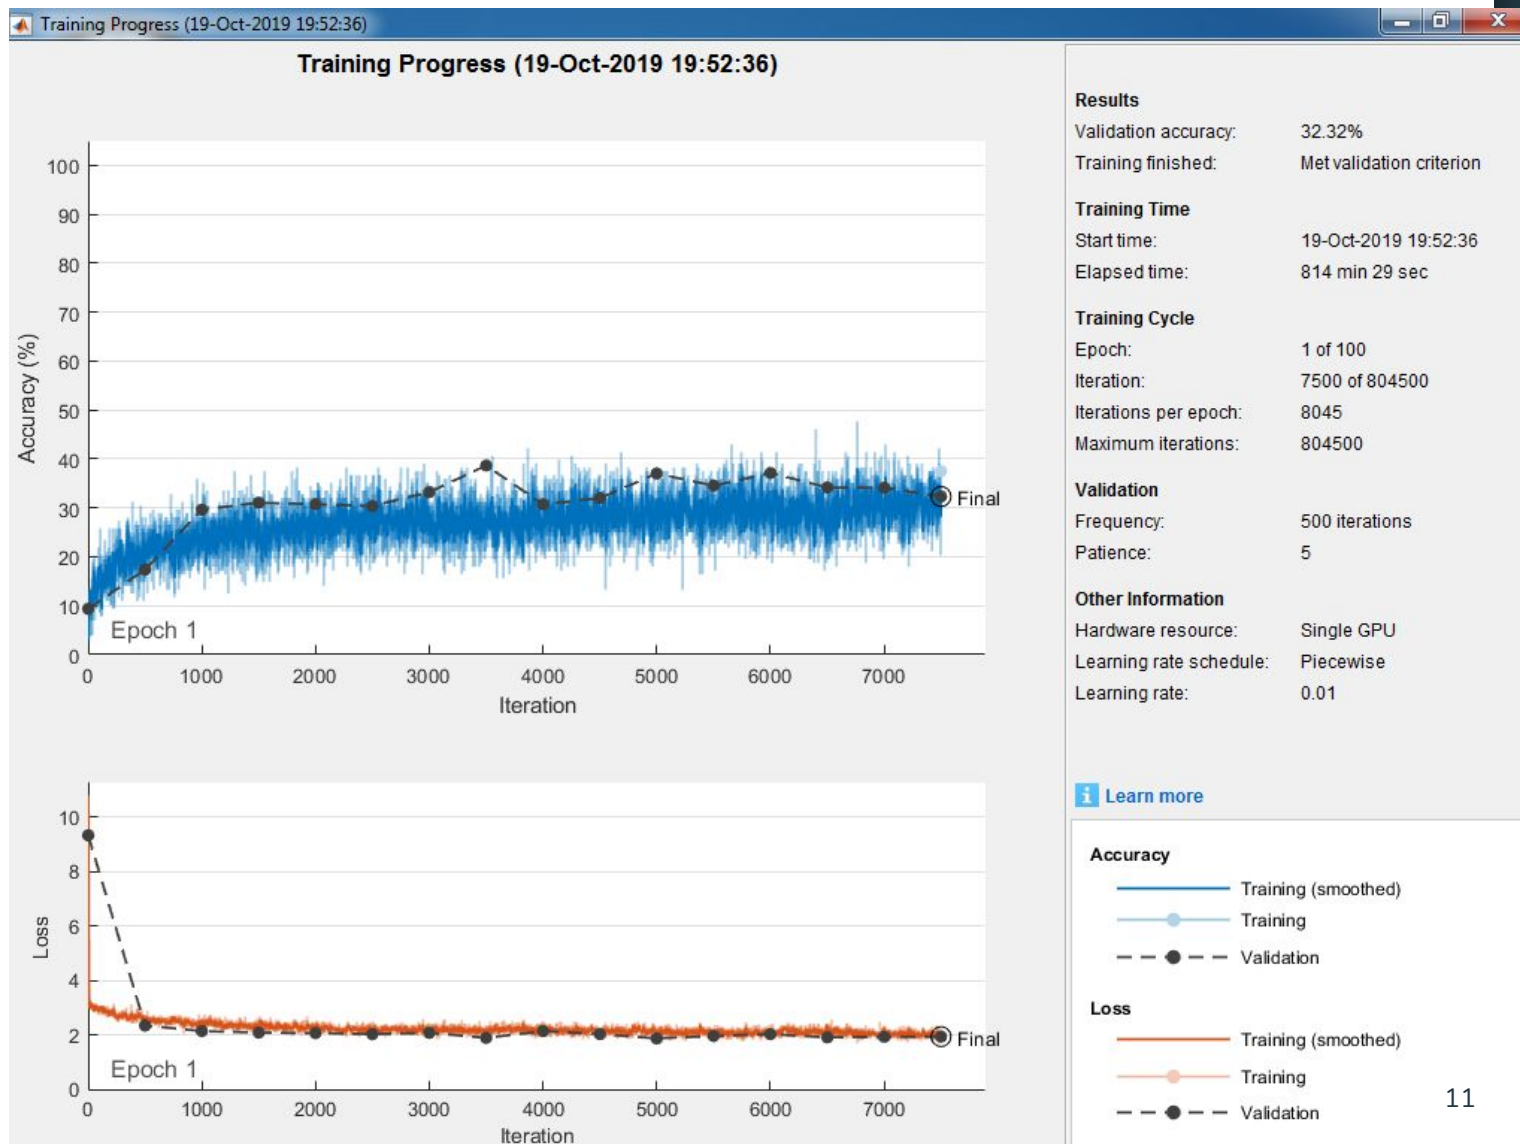
Wagi warstwy conv1 20x3x128



Wstępne wyniki uczenia

67 klas


TOP5 76%



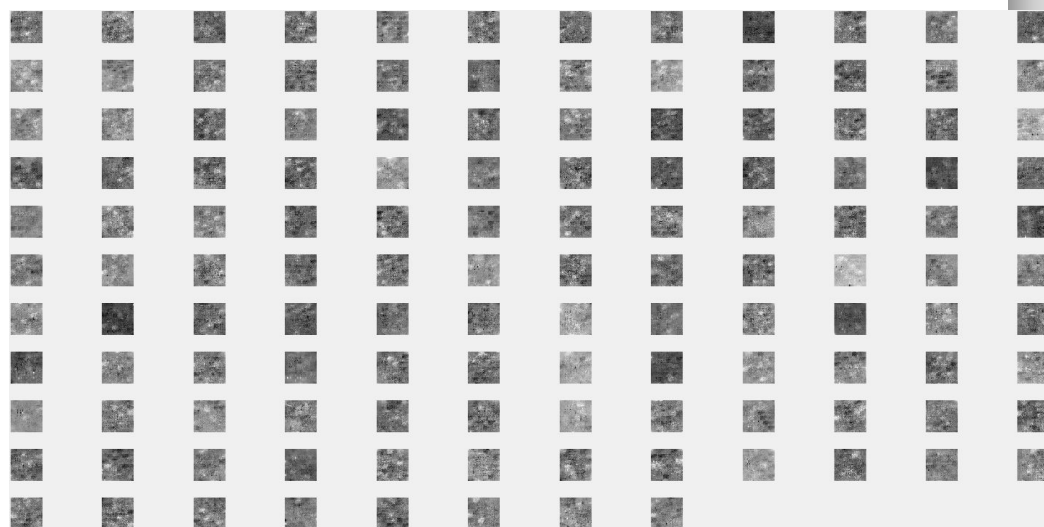
Inne rozwiązania

Sieci z 2 warstwami konwolucyjnymi i 2 w pełni połączonymi z różnymi rozmiarami wejścia i wyjścia

W znalezionych pracach [1] i [3] zostały wykonane jeszcze prostsze sieci z wejściem 20x20 i tylko jedną warstwą konwolucyjną, jednak ze względu na mały rozmiar wejścia te architektury źle rokują dla naszych danych



Wizualizacja DeepDream [5] filtrów pierwszej warstwy konwolucyjnej



Wizualizacja DeepDream [5] filtrów drugiej warstwy konwolucyjnej

Zebrane dane

540 filmów po 500
klatek

7 substancji

26 serii produktów

8 rozcieńczeń

20 rozmiarów cząstek

7 czasów ekspozycji

Raport z 16szej serii pomiarów rozproszonych dla celów projektu "Zastosowanie metod sieci neuronowych do automatycznego wyznaczania właściwości próbki zawiesiny"												
Rejestrowano rozpraszanie po katem 26 Serii w celu umożliwienia ewentualnego śledzenia ruchu "speculi". Maksymalizowano szybkość nagrywania (k/s). Ekspozycję doświetlenia w celu maksymalizacji dynamiki obrazów - kamera Pike (Allied Vision) w trybie RAW/6 (obraz 14-bitowy). Szereg filmów (~500 klatki; ~300MB) odpowiadających różnym zawiesinom - kilka lokalizacji wiązek względem kulek. Kulełka cienka (0.1mm) oświetlona prostokątem wiązki 822nm. Szczegóły w załączniku dołączonym DJ.												
Numer pliku	Plik	Uwagi	substancja cząstek	serie produktu	koncentracja wlg procenta (w/v)	rozcieńczenie podstawowej próbki	Rozmiar cząstek (nm)	Czas ekspozycji (s)	Liczba k/s	Liczba klatek	Kat ośniewi	
37	026_Sdeg_shutter.in microsec20475_49fps@IQ_40nm_v3.avi	9.2011	Au	13619	5.82E-03		40	20.475	49	26.9		
38	026_Sdeg_shutter.in microsec20475_49fps@IQ_10nm.avi	10.2018	8IQ2	IPIL	5		10	20.475	49	26.9		
39	026_Sdeg_shutter.in microsec20475_49fps@IQ_10nm_v2.avi	10.2018	8IQ2	IPIL	5		10	20.475	49	26.9		
40	026_Sdeg_shutter.in microsec20475_49fps@IQ_10nm_v3.avi	10.2018	8IQ2	IPIL	5		10	20.475	49	26.9		
41	026_Sdeg_shutter.in microsec20475_49fps@IQ_72nm.avi		8IQ2	765	5		72	20.475	49	26.9		
42	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+1H2O.avi	10ul próbki +10ul Aq. dest.	8IQ2	NX780	5	1:1	252.2	300	80	26.9		
43	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+1H2O_v2.avi	10ul próbki +10ul Aq. dest.	8IQ2	NX780	5	1:1	252.2	300	80	26.9		
44	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+1H2O_v3.avi	10ul próbki +10ul Aq. dest.	8IQ2	NX780	5	1:1	252.2	300	80	26.9		
45	026_Sdeg_shutter.in microsec8_80fps@IQ_447.3.avi	był powtórzony jako 137	8IQ2	083e	5		447.3	5	80	26.9		
46	026_Sdeg_shutter.in microsec8016_80fps@Ag_10nm.avi	PUA H2O nic nie wiemy	Ag				10	8016	80	26.9		
47	026_Sdeg_shutter.in microsec8016_80fps@Ag_10nm_v2.avi	PUA H2O nic nie wiemy	Ag				10	8016	80	26.9		
48	026_Sdeg_shutter.in microsec8016_80fps@Ag_10nm_v3.avi	PUA H2O nic nie wiemy	Ag				10	8016	80	26.9		
49	026_Sdeg_shutter.in microsec8016_80fps@Au_100nm.avi		Au	18914	5.66E-03		100.6	8016	80	26.9		
50	026_Sdeg_shutter.in microsec8016_80fps@Au_100nm_v2.avi		Au	18914	5.66E-03		100.6	8016	80	26.9		
51	026_Sdeg_shutter.in microsec8016_80fps@Au_100nm_v3.avi		Au	18914	5.66E-03		100.6	8016	80	26.9		
52	026_Sdeg_shutter.in microsec8016_80fps@Au_20nm.avi		Au	019197	5.66E-03		20	8016	80	26.9		
53	026_Sdeg_shutter.in microsec8016_80fps@Au_20nm_v2.avi		Au	019197	5.66E-03		20	8016	80	26.9		
54	026_Sdeg_shutter.in microsec8016_80fps@Au_20nm_v3.avi		Au	019197	5.66E-03		20	8016	80	26.9		
55	026_Sdeg_shutter.in microsec8016_80fps@Au_260nm.avi		Au	020766	5.66E-03		254.4	8016	80	26.9		
56	026_Sdeg_shutter.in microsec8016_80fps@Au_260nm_v2.avi		Au	020766	5.66E-03		254.4	8016	80	26.9		
57	026_Sdeg_shutter.in microsec8016_80fps@Au_260nm_v3.avi		Au	020766	5.66E-03		254.4	8016	80	26.9		
58	026_Sdeg_shutter.in microsec8016_80fps@Au_30nm.avi		Au	13719	5.46E-03		30	8016	80	26.9		
59	026_Sdeg_shutter.in microsec8016_80fps@Au_30nm_v2.avi		Au	13719	5.46E-03		30	8016	80	26.9		
60	026_Sdeg_shutter.in microsec8016_80fps@Au_30nm_v3.avi		Au	13719	5.46E-03		30	8016	80	26.9		
61	026_Sdeg_shutter.in microsec8016_80fps@Au_40nm.avi	9.2011	Au	13616	5.82E-03		40	8016	80	26.9		
62	026_Sdeg_shutter.in microsec8016_80fps@Au_40nm_v2.avi	9.2011	Au	13616	5.82E-03		40	8016	80	26.9		
63	026_Sdeg_shutter.in microsec8016_80fps@Au_40nm_v3.avi	9.2011	Au	13617	5.82E-03		40	8016	80	26.9		
64	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm.avi		Au	019874	5.66E-03		91.2	8016	80	26.9		
65	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm_v2.avi		Au	019874	5.66E-03		91.2	8016	80	26.9		
66	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm_v3.avi		Au	019874	5.66E-03		91.2	8016	80	26.9		
67	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm_v4.avi		Au	13692	5.66E-03		60	8016	80	26.9		
68	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm_v5.avi		Au	13693	5.66E-03		60	8016	80	26.9		
69	026_Sdeg_shutter.in microsec8016_80fps@Au_60nm_v6.avi		Au	13694	5.66E-03		60	8016	80	26.9		
70	026_Sdeg_shutter.in microsec8016_80fps@IQ_101.5nm.avi		8IQ2	NX731	5		101.9	8016	80	26.9		
71	026_Sdeg_shutter.in microsec8016_80fps@IQ_101.5nm_v2.avi		8IQ2	NX731	5		101.9	8016	80	26.9		
72	026_Sdeg_shutter.in microsec8016_80fps@IQ_101.5nm_v3.avi	nowsze próbki: 10.2018	8IQ2	NX731	5		101.9	8016	80	26.9		
73	026_Sdeg_shutter.in microsec8016_80fps@IQ_101.5nm_v4.avi	nowsze próbki: 10.2018	8IQ2	NX731	5		101.9	8016	80	26.9		
74	026_Sdeg_shutter.in microsec8016_80fps@IQ_62.7nm.avi		8IQ2	NX086	5		62.7	8016	80	26.9		
75	026_Sdeg_shutter.in microsec8016_80fps@IQ_62.7nm_v2.avi		8IQ2	NX086	5		62.7	8016	80	26.9		
76	026_Sdeg_shutter.in microsec8016_80fps@IQ_62.7nm_v3.avi		8IQ2	NX086	5		62.7	8016	80	26.9		
77	026_Sdeg_shutter.in microsec8016_80fps@IQ_66.7nm.avi	10.2018	8IQ2	NX712	5		66.7	8016	80	26.9		
78	026_Sdeg_shutter.in microsec8016_80fps@IQ_66.7nm_v2.avi	10.2018	8IQ2	NX712	5		66.7	8016	80	26.9		
79	026_Sdeg_shutter.in microsec8016_80fps@IQ_66.7nm_v3.avi	10.2018	8IQ2	NX712	5		66.7	8016	80	26.9		
80	026_Sdeg_shutter.in microsec8016_80fps@IQ_72nm.avi		8IQ2	765	5		72	8016	80	26.9		
81	026_Sdeg_shutter.in microsec8016_80fps@IQ_72nm_v2.avi		8IQ2	765	5		72	8016	80	26.9		
82	026_Sdeg_shutter.in microsec8016_80fps@stap_violet.avi		woda z kranu					8016	80	26.9		
83	026_Sdeg_shutter.in microsec8016_80fps@ultrapure_water.avi		ultra czysta woda					8016	80	26.9		
84	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
85	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O_v2.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
86	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O_v3.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
87	026_Sdeg_shutter.in microsec105_80fps@IQ_262.2nm+2H2O.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	105	80	26.9		
88	026_Sdeg_shutter.in microsec105_80fps@IQ_262.2nm+2H2O_v2.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	105	80	26.9		
89	026_Sdeg_shutter.in microsec105_80fps@IQ_262.2nm+2H2O_v3.avi	5ul próbki + 10ul Aq. dest.	8IQ2	NX780	5	1:2	252.2	105	80	26.9		
90	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O_v4.avi	04.10.2019	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
91	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O_v5.avi	04.10.2019	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
92	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+2H2O_v6.avi	04.10.2019	8IQ2	NX780	5	1:2	252.2	300	80	26.9		
93	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+3H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	300	80	26.9		
94	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+3H2O_v2.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	300	80	26.9		
95	026_Sdeg_shutter.in microsec300_80fps@IQ_262.2nm+3H2O_v3.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	300	80	26.9		
96	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+3H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	600	80	26.9		
97	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+3H2O_v2.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	600	80	26.9		
98	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+3H2O_v3.avi	04.10.2019	8IQ2	NX780	5	1:3	252.2	600	80	26.9		
99	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+4H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	600	80	26.9		
100	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+4H2O_v2.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	600	80	26.9		
101	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+4H2O_v3.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	600	80	26.9		
102	026_Sdeg_shutter.in microsec1490_80fps@IQ_262.2nm+4H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	1490	80	26.9		
103	026_Sdeg_shutter.in microsec1490_80fps@IQ_262.2nm+4H2O_v2.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	1490	80	26.9		
104	026_Sdeg_shutter.in microsec1490_80fps@IQ_262.2nm+4H2O_v3.avi	04.10.2019	8IQ2	NX780	5	1:4	252.2	1490	80	26.9		
105	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+8H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:5	252.2	600	80	26.9		
106	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+8H2O_v2.avi	04.10.2019	8IQ2	NX780	5	1:5	252.2	600	80	26.9		
107	026_Sdeg_shutter.in microsec600_80fps@IQ_262.2nm+8H2O_v3.avi	04.10.2019	8IQ2	NX780	5	1:5	252.2	600	80	26.9		
108	026_Sdeg_shutter.in microsec1490_80fps@IQ_262.2nm+8H2O_v1.avi	04.10.2019	8IQ2	NX780	5	1:5	252.2	1490	80	26.9		

Prace planowane i zaczęte

Badane różnych grupowań w klasy - wnioski o niesionej informacji *

Badania zmian struktury sieci *

Wpływ wcześniejszego przetwarzania danych na dokładność sieci i jej uczenie *

Badanie wpływu zmiany ilości danych na dokładność sieci *

Zebranie większej ilości danych *

Znalezienie i zapoznanie się z innymi podobnymi rozwiązaniami *

Badanie wpływu zmiany ilości danych na dokładność sieci

Zwiększenie ilości danych około 9 razy z około 30000 do około 250000 dało pewien wzrost dokładności,


Z $\text{top1} = 0.1993$ i $\text{top5} = 0.3947$ na $\text{top1} = 0.2262$ i $\text{top5} = 0.5350$

ale trening zajął też więcej czasu


Z 394 minuty na 1924 minuty

Do tej pory trenowałem około 50 różnych sieci

Niesiona informacja



PS MKBS9398V 1:1 wycinek 64x64 po normalizacji z odjęciem tła



SiO2 NX780 1:6 wycinek 64x64 po normalizacji z odjęciem tła

[1] - Struktura powierzchni - rozmiar spekli

W polu speklowym informacja jest powtórzona

Pole speklowe jest przestrzenne

Pole speklowe zawiesiny nanocząstek w cieczy jest dynamiczne - nanocząstki ciągle się przemieszczają

Spekle szybko się przemieszczają

Ruch może nieść informacje o stosunku masy cząstek do lepkości cieczy


Wpływ wcześniejszego przetwarzania danych na dokładność sieci i jej uczenie

W pierwszym podejściu - normalizacja zakresu jasności


Podejście 2 uzasadnione teorią - odjęcie tła i normalizacja zakresu jasności

Usunięcie informacji rezydualnej takiej jak zanieczyszczenie aparatury wydobywa informację o ruchu na wierzch, ale też uniemożliwia systemom nauczania się korelacji tej informacji rezydualnej z konkretnym pomiarem - wzrost czasu uczenia i spadek maksymalnej dokładności

Filtry HOG - nie wykazują się lepszym zachowaniem od warstw konwolucyjnych, a ich wyliczenie jest bardzo czasochłonne



PS 1100nm klatka 1 bez odjęcia tła



PS 1100nm klatka 1 z odjęciem tła

Badania zmian struktury sieci

Rozmiar wejścia - z małym obrazem wejściowym który zawiera kilka - kilkadziesiąt pikseli uczenie przebiega szybciej, z dużym rozmiarem wejścia sieć nie chce wyjść z poziomu klasyfikatora losowego - prawdopodobnie zbyt duża chaotycznych informacji.

Bardzo silny wpływ ilości klas wyjściowych na szybkość uczenia sieci i jej dokładność - dla 2 klas sieć uzyskuje dużą dokładność, a już z 3 klasami zaczynają się problemy.

Transfer learning w celu zmienianie struktury sieci rozmiaru wejścia wyjścia można użyć wag warstw których rozmiary nie uległy zmianie znacznie przyspiesza uczenie pozwala nauczyć sieć z rozmiarami wejść / wyjść nawet jeśli w uczeniu sieci z wag losowych nie było widać wychodzenia z poziomu klasyfikatora losowego.

Gdy wydaje się, że uczenie sieci zatrzymało się na pewnym poziomie dokładności często skuteczne jest dodanie do wag warstw sieci losowych macierzy, pozwala to algorytmowi uczenia na wyjście z lokalnych minimów [4]

Dość płytka sieć konwolucyjna wykazuje się dużą skutecznością i krótszym czasem uczenia [1][3] - Strategia najpierw sieć płytka z możliwie dużą dokładnością, potem pogłębianie z transfer learningiem i badanie dokładności.

Porównanie CNN z SVM

Dla sieci z odjętym tłem najlepszy do tej pory wynik dokładności
top1 = 0.2262 , top5 = 0.5350

Najlepszy SVM (filtry HOG 4x4, obrazy 64x64) linowy dokładność:
0.1993


SVM z jądrem RBF: 0.0201

SVM z jądrem wielomianowym: 0.0823

Nie zauważyłem poprawy przy zmianie parametru C

Filtry HOG 2x2 dla takiego obrazu nie pozwalają zmieścić danych w
pamięci

Filtry HOG 8x8 tracą podobieństwo do obrazu wejściowego -
rozmiar szczegółów cech w obrazie jest zbyt mały




Porównanie wycinku klatki rozmiaru 4x4 i filtrów HOG

Analiza tablicy pomyłek

Z tablicy pomyłek można próbować odczytać podobieństwo klas, nie ma gwarancji, że klasy które uważamy za podobne będą częściej klasyfikowane ze sobą na odwrót, ale jeśli tak jest, to może to potwierdzać wartościowość metody.

Można się spodziewać, że takie relacje podobieństwa mogą być zwrotne, przechodnie i symetryczne.



Bibliografia

- [1] - VALENT, Eadan; SILBERBERG, Yaron. Scatterer recognition via analysis of speckle patterns. *Optica*, 2018, 5.2: 204-207.
- [2] - KRIZHEVSKY, Alex; SUTSKEVER, Ilya; HINTON, Geoffrey E. Imagenet classification with deep convolutional neural networks. In: *Advances in neural information processing systems*. 2012. p. 1097-1105.
- [3] - KÜRÜM, Ulas, et al. Deep learning enabled real time speckle recognition and hyperspectral imaging using a multimode fiber array. *Optics express*, 2019, 27.15: 20965-20979.
- [4] -WANG, Rong-Long; ZHANG, Cui; OKAZAKI, Kozo. A new method of learning for multi-layer neural network. *IJCSNS*, 2007, 7.5: 86.
- [5] <https://deepdreamgenerator.com/>

Koniec